

pico-JEPA v2: ¿Cuándo superan muchos modelos pequeños a uno grande?

Conjuntos heterogéneos y apilamiento para aprender video sin etiquetas en una PC de fácil acceso

Adrián Rostagno · Javier Iparraguirre · Roberto Briatore
Agustín González · Santiago Aggio

Universidad Tecnológica Nacional — Facultad Regional Bahía Blanca
{arostag, jiparraguirre, rbriatore, agonzalez, slaggio}@frbb.utn.edu.ar

XXXII Congreso Argentino de Ciencias de la Computación (CACIC 2026)
Facultad Regional Concepción del Uruguay, UTN · 6 al 8 de octubre de 2026

github.com/BHI-Research/pico-jepa-v2

Entender video cuesta caro: etiquetas, datos y cómputo

- ▶ Etiquetar video a mano es lento y costoso.
- ▶ El aprendizaje auto-supervisado aprende mirando videos sin etiquetas.
- ▶ Pero los modelos de referencia se entrenan a escala industrial.
- ▶ Nuestro escenario: **una PC de escritorio con una GTX 1060 de 6 GB.**

DATOS

≈ 670×

menos videos de
pre-entrenamiento
que V-JEPA

PARÁMETROS

≈ 300×

menos que el
codificador más
grande de V-JEPA 2

HARDWARE

6 GB


de memoria de
video: una sola GPU
de escritorio

Pregunta central

Con cómputo y datos fijos, ¿conviene un único modelo entrenado con todo... o varios modelos pequeños, cada uno con una porción distinta, que combinan sus predicciones?

«La unión hace la fuerza», pero no siempre: la pregunta interesante es cuándo.

Antecedentes: de nano-JEPA a pico-JEPA v2



Qué aporta v2

- 1 Conjunto heterogéneo**
cada submodelo lleva una cabeza distinta
- 2 Apilamiento**
un meta-modelo aprende a quién escuchar
- 3 Estadística formal**
bootstrap, IC 95 % y verificación de robustez
- 4 Mapa de condiciones**
cuándo aparece y cuándo desaparece la ventaja

De «compite con el modelo único» a «lo supera, y sabemos cuándo».

Estado del arte I: aprendizaje autosupervisado con JEPA

¿Qué propone JEPA?


- ▶ JEPA aprende **sin etiquetas**, prediciendo representaciones de partes ocultas de los datos.
- ▶ A diferencia de los métodos de reconstrucción, **no intenta recuperar píxeles**, sino información relevante en el espacio de representación.
- ▶ En video, **V-JEPA** extiende esta idea aprendiendo relaciones espaciales y temporales entre distintas regiones de una secuencia.
- ▶ El objetivo es obtener representaciones **semánticas y útiles**, evitando dedicar capacidad a detalles visuales poco relevantes.

¿Por qué es interesante para nuestra investigación?

Al trabajar directamente sobre representaciones y evitar la reconstrucción de píxeles, JEPA ofrece una base atractiva para desarrollar modelos autosupervisados más eficientes y compactos.

Estado del arte II: la sabiduría colectiva de los modelos


Ejemplo: cuatro modelos clasifican el mismo video



Votación: cómo decide un conjunto


- ▶ Cada modelo opina y el conjunto decide entre todos.
- ▶ Funciona si los errores son distintos: los aciertos se repiten y los errores se compensan.
- ▶ Dura: gana la clase más elegida. Blanda: se promedian las probabilidades. Ponderada: pesa más quien rindió mejor.
- ▶ Votar aplica una regla fija; el apilamiento aprende de los datos a quién escuchar.

Etapa 1: «completar lo que falta» sin etiquetas



- ▶ Se ve el 20 % de los parches (contexto) y se predice el 80 % oculto, con ocultamiento multibloque (3 bloques).
- ▶ La predicción ocurre en el espacio de representaciones, no en píxeles.
- ▶ El codificador objetivo es un promedio móvil y no recibe gradiente: así se evita el colapso.
- ▶ ViT compacto: $d = 192$, 8 capas, 8 cabezas, ≈ 3.4 M de parámetros; 20 épocas sobre 3 000 videos.

Etapa 2: cuatro submodelos distintos que deciden juntos



- ▶ Los cuatro submodelos parten del mismo codificador de la Etapa 1: solo cambia la cabeza de clasificación.
- ▶ Cada submodelo entrena con 1/4 de los 876 videos (≈ 219), con las 30 clases representadas por igual.
- ▶ Cabezas distintas (lineal, MLP-2, atencional) y congelado o ajuste fino: así cada uno se equivoca en casos distintos.
- ▶ El modelo único ve los 876 videos con una sola cabeza; la brecha Δ mide cuánto gana o pierde el conjunto frente a él.

Diseño experimental: una sola métrica y veredictos fijados de antemano

Kinetics-700-2020 [18] · 30 clases · 1 467 videos etiquetados · partición fija (semilla 1337)

Entrenamiento · 876

ajusta M1–M4 y el modelo único

Validación · 297

elige la configuración y
entrena el apilamiento

Reservado · 294

se usa solo para medir la
brecha

Métrica única: la brecha Δ

$$\Delta = \text{exact}_{\text{conj}} - \text{exact}_{\text{único}}$$

- ▶ En puntos porcentuales, sobre el conjunto reservado.
- ▶ Cada video: probabilidades promediadas sobre 10 fragmentos.
- ▶ Bootstrap: 10 000 remuestreos (semilla 1337) → IC 95 %.

Todo corre en una PC: Intel Core i7 · NVIDIA GTX 1060 (6 GB)

Veredictos fijados de antemano

SOPORTADO

todo el IC 95 % por encima de 0


INCONCLUSO

$\Delta > 0$, pero el IC contiene el 0

RECHAZADO

$\Delta \leq 0$

Exploración automatizada: nueve mediciones, nueve brechas positivas




- Un bucle inspirado en autoresearch propone configuraciones, entrena los modelos reales y registra todo con la métrica fijada.
- **9 de 9 brechas positivas**, con promedio +2.53 pp.
- Si la brecha real fuera cero, sería como sacar nueve caras seguidas con una moneda:

$$0.5^9 \approx 0.002$$

Resultado central: solo el apilamiento gana con significancia

Experimento controlado: mismos cuatro submodelos y mismo modelo único; solo cambia la forma de combinar.



Lo que muestra el experimento

Las tres votaciones mejoran algo, pero sus intervalos incluyen el cero. Solo el apilamiento, que aprende a quién escuchar en cada clase, supera al modelo único con significancia (+75 % de exactitud relativa). **La diversidad sola no alcanza: hay que aprender a combinarla.**

¿Cuándo funciona y cuándo no? El mapa de condiciones

d = 192
capacidad

30 clases

SOPORTADO

$\Delta = +5.10$ pp

IC 95 % [+0.68, +9.19]
configuración principal

10 clases

RECHAZADO

$\Delta = -1.50$ pp

modelo único: 22.5 %

Capacidad suficiente

Con menor capacidad, los submodelos tienden a aprender soluciones similares y la ventaja desaparece.

Espacio de clases amplio

Con pocas clases ocurre algo parecido: disminuye la diversidad entre los submodelos.

d = 128
capacidad

RECHAZADO

$\Delta = 0.00$ pp

IC [-0.04, +0.04]
modelo único: 11.6 %

sin explorar
trabajo futuro


Mecanismo común

La ventaja depende de la diversidad: si los submodelos convergen a soluciones similares, el apilamiento ya no tiene diferencias que aprovechar.

Conclusiones: dividir puede ganar, pero no gratis

Resultado Principal.

El aporte central no es solo mostrar que varios modelos pequeños pueden ganar ante uno grande, sino identificar las condiciones bajo las cuales esa ventaja aparece o desaparece.



Trabajo futuro

Ampliar el preentrenamiento sin etiquetas y estudiar con mayor resolución dónde aparece y desaparece la ventaja al variar capacidad y cantidad de clases.

¡Gracias!

¿Preguntas?

github.com/BHI-Research/pico-jepa-v2